

实验报告

面向 Spider Text-to-SQL 的迭代式数据选择

Spider 1.0 + CodeT5-small | 2026年9月21日

本研究在固定 500 个样本的数据预算下，迭代式、模型感知的数据选择能否改善 Text-to-SQL 微调。实验同时评估基于观测损失的 IDU 改造，以及结合 EXP3 与累积回放的训练期梯度 IDU 改造。所有主要方法均使用 5 个固定随机种子，并采用 Spider 官方 Exact Match 评估器。

执行摘要

基于观测损失的 IDU 在所有选数方法中取得最高平均成绩 17.08%，随机选择为 15.64%。更贴近 LEAD 论文的训练期梯度改造，在使用 EXP3 和累积回放时取得 15.94%。它在 5 个随机种子中的 3 个超过随机方法，但配对 95% 区间仍跨越 0。因此，两种自适应方法都不足以支持“稳定优于基线”的结论。

全量数据训练仍明显更强，达到 23.02%。动态梯度方法端到端耗时 489.2 秒，比全量数据少 29.4%，但准确率低 7.08 个百分点。因此，证据表明存在可测量的成本-质量权衡，而不是达到了全量数据的性能。

1. 研究问题

Q1：使用 500 个选定样本进行微调，能否达到或超过使用全部 1,000 个候选样本训练的结果？

Q2：在相同选数预算和优化步数预算下，迭代式模型感知选择是否优于随机选择？

Q3：迭代方法能否改善端到端的性能-成本权衡？

Q4：相较于预先固定一个数据子集，迭代式选择是否有帮助？梯度 IDU 和 EXP3 是否能带来稳定增益？

2. 实验设计

项目	受控设置
数据集	Spider 1.0；1,000 个训练候选样本；完整的 1,034 个开发集样本
模型	Salesforce CodeT5-small
选数预算	每一种选数方法均为 500 个样本
随机种子	11、42、73、101、202
主要指标	Spider 官方 Exact Match
选定数据训练	五轮方法：每轮 100 个样本；采用累积并集；共 1,500 个优化步
成本范围	选择/评分 + 训练 + 生成 + 官方评估

公平性控制

随机方法和所有迭代式选数方法使用相同的 500 样本预算、模型、随机种子、开发集和主要指标。所有五轮方法也共享相同的累积训练计划和总优化步数预算。全量数据方法使用全部 1,000 个样本训练 3 个 epoch，其更高的训练成本被计入端到端比较。

3. 将 LEAD 改造到 Spider

LEAD 使用迭代式模型反馈、实例级动态不确定性 (Instance-Level Dynamic Uncertainty, IDU)，以及基于多臂老虎机的由粗到细资源分配。本项目实现了一个透明、计算上可承受的 Spider 改造，并明确区分与论文一致的组件和针对任务所作的近似。

- 静态不确定性方法仅按照预训练模型的目标损失排序一次，之后不再更新样本效用。
- 观测损失 IDU 每轮选择 100 个样本，在累计已选数据上训练，再根据实测目标损失的变化重新调整样本效用，然后选择下一批数据。
- 梯度 IDU 在正常训练期间，从 CodeT5 最后一个 decoder block 估计一阶损失变化，并进行历史平滑，因此无需单独对剩余候选池再做一次评分。
- 动态方法进一步加入基于损失分位数的难度簇、Spider 数据库任务组、依据有界 IDU 降低奖励进行的 EXP3 分配，以及跨 5 轮的累积回放。
- 平衡簇回放对照保持梯度 IDU、分组、回放、数据预算和优化步数不变，只将 EXP3 替换为固定日程 0、1、0、1、0。

梯度更新： $u_i(r) = (1-\beta) \max[0, L_i + g_i^T d\theta] + \beta u_i(r-1)$ 。
所跟踪的梯度/参数更新内积，是对下一次损失的一阶近似；在进行历史平滑前，将交叉熵下限截断为 0。

聚焦假设与竞争性解释

假设：训练期梯度 IDU 与 EXP3 能够比随机选择和固定簇日程获得更好的性能-成本权衡。竞争性解释：任何增益都可能主要来自累积回放和对旧样本的重复暴露，而不是自适应 bandit 分配。平衡回放对照在保留其余训练设计的同时，用于隔离这一解释。




图 1：五轮动态梯度 LEAD 改造及其匹配的评估边界。

4. 主要性能与成本结果

方法	官方 EM	端到端时间	覆盖数据库数
全量数据	23.02% +/- 1.83 个百分点	692.8 秒	137.0
随机选择	15.64% +/- 1.13 个百分点	502.4 秒	126.8
两轮迭代	13.56% +/- 1.92 个百分点	510.3 秒	124.0
五轮完整改造	15.22% +/- 2.96 个百分点	605.0 秒	123.2
五轮 IDU-only	17.08% +/- 2.39 个百分点	527.3 秒	119.2
静态不确定性	13.82% +/- 2.37 个百分点	457.5 秒	114.0
Cluster-MAB 组件	14.24% +/- 1.13 个百分点	629.8 秒	120.2
数据库配额组件	15.52% +/- 2.04 个百分点	582.3 秒	111.0
动态梯度 + EXP3	15.94% +/- 2.32 个百分点	489.2 秒	123.2
平衡梯度对照	15.02% +/- 3.05 个百分点	430.9 秒	122.0




图 2：初始比较方法的平均官方 Exact Match 与实测端到端时间。

配对随机种子分析

IDU-only 相对随机方法在 5 个随机种子上的差值依次为 +1.8、-2.4、+3.5、+5.5 和 -1.2 个百分点。精确符号翻转检验的 p 值为 0.4375。只有 5 个种子时统计功效较低，因此正确结论是：观察到了平均优势，但结果对随机种子具有明显敏感性。

对 Q1-Q4 的回答

- Q1：不能。表现最好的选数方法仍比全量数据低 5.94 个百分点。
- Q2：部分成立。观测损失 IDU 在选数方法中平均成绩最高；动态梯度选择仅比随机方法高 0.30 个百分点，不能认为它稳定优于随机方法。
- Q3：可以视为一种权衡，但不是全面占优。动态梯度选择明显快于全量数据，但准确率差距仍然较大；它与随机方法之间很小的时间差不应被过度解读。
- Q4：部分成立。观测损失 IDU 优于预先固定的静态对照，说明迭代更新样本效用可能有帮助。然而，梯度 IDU + EXP3 仅比随机方法高 0.30 个百分点，比平衡对照高 0.92 个百分点；两项配对 95% 区间均跨越 0。它改变了选择路径，但没有带来稳定增益。

5. 难度与 SQL 组件分析




图 3：按 Spider 官方难度划分的平均 Exact Match。

方法	简单	中等	困难	超难	全部
全量数据	50.72%	18.62%	16.20%	0.72%	23.02%
随机选择	34.94%	12.96%	8.96%	1.20%	15.64%
五轮 IDU-only	37.64%	14.94%	9.54%	0.00%	17.08%

IDU-only 相比随机方法，在简单、中等和困难样本上分别提高 +2.70、+1.98 和 +0.58 个百分点，但在 5 次实验中没有解对任何超难样本。因此，其收益主要集中在结构要求较低的查询上。




图 4：IDU-only 相对随机方法在官方 partial-match F1 上的差值；图中排除了稀疏的 IUEN 组件。

最稳定的正向差异来自：无聚合的 SELECT (+3.68 个百分点)、SELECT (+3.62 个百分点) 以及无运算符的 WHERE (+3.20 个百分点)。GROUP 略低 (-0.66 个百分点)。官方 IUEN 组件非常稀疏；当某次运行没有生成匹配的集合操作时，该指标不稳定，因此不对其较大的数值差异进行单独解释。

6. 消融实验说明了什么

比较	平均差值	解释
IDU-only vs 静态	+3.26 个百分点	在线更新样本效用能够增加价值。
IDU-only vs 完整改造	+1.86 个百分点	将所有分配组件一起加入并没有帮助。
IDU-only vs Cluster-MAB	+2.84 个百分点	当前聚类与 bandit 分配过于粗糙或不稳定。
IDU-only vs 数据库配额	+1.56 个百分点	比例配额降低了有效选择的灵活性。

核心正向结果并不是完整的 LEAD-style 改造获胜。相反，最简单的迭代组件，也就是根据模型反馈更新样本效用，是表现最强的变体。加入簇调度或数据库配额会增加成本，却没有提高平均性能。

选择行为

IDU-only 与随机方法的已选集合平均 Jaccard 重叠为 0.329。IDU-only 平均覆盖 119.2 个数据库，而随机方法覆盖 126.8 个。它观察到的优势并不是来自最大化数据库数量，而是来自选择一个不同的、动态更新的数据子集。

7. 基于梯度的 LEAD 验证

比较	平均差值	95% 配对区间	胜出次数
动态 vs 平衡对照	+0.92 个百分点	[-3.30 个百分点, +5.14 个百分点]	3/5
动态 vs 随机	+0.30 个百分点	[-3.02 个百分点, +3.62 个百分点]	3/5
动态 vs 观测损失 IDU	-1.14 个百分点	[-6.27 个百分点, +3.99 个百分点]	1/5
动态 vs 全量数据	-7.08 个百分点	[-9.89 个百分点, -4.27 个百分点]	0/5

累积回放是最清晰的成功设计改动。对于随机种子 42，梯度方法从不使用回放时的 10.3% 提升到使用回放时的 19.5%。这一单种子对比促成了后续多种子验证，但不能把它当作平均效应。

在 5 个随机种子上，动态梯度 + EXP3 的结果为 15.94% +/- 2.32 个百分点。它平均比匹配的平衡对照高 0.92 个百分点，比随机方法高 0.30 个百分点，但两个配对区间都跨越 0。它比观测损失 IDU 低 1.14 个百分点。正确解释应是：性能具有竞争力但不稳定，而不是可靠地优于其他方法。

动态选择的平均两两 Jaccard 重叠为 0.80，固定日程则为 1.00。因此 EXP3 确实改变了选择路径，但仅有 5 次分配决策不足以学习出一个稳定更优的策略。奖励也主要随训练轮次增加，说明轮次进展与难度臂价值没有被清晰分离。

8. 人工核查的定性案例

IDU-only 的优势：分组与 HAVING

对于问题“列出至少有两个段落的所有文档 ID”，IDU-only 在 5 个种子中的 4 个生成了正确的 Paragraphs + GROUP BY + HAVING 结构。随机方法在 5 个种子中全部失败，常见错误包括使用 Documents 表，或用 ORDER BY 和 LIMIT 替换 HAVING。

IDU-only 的优势：模式链接与比较

对于“1950 年之后独立的国家”，IDU-only 在 4 个种子中生成了直接使用 country/IndepYear > 1950 的查询。随机方法经常错误选择 city 表、使用等号，或选择错误的列。

随机方法的优势：否定条件

对于“国籍不等于 Russia”，随机方法在 4 个种子中保留了不等号。IDU-only 在所有种子中均失败，常见错误是反转条件，或生成不必要的嵌套 NOT IN 查询。

随机方法的优势：字面值保留

对于剧集名称“A Love of a Lifetime”，随机方法在 4 个种子中保留了完整字面值。IDU-only 则反复缩短该字面值，或选择无效的输出列。

仅涉及格式的失配，例如引号样式或标识符大小写，不计入实质性案例分析。这些案例可以解释方法行为，但不能替代官方汇总指标。

9. 局限性

- 5 个随机种子能够暴露不稳定性，但不足以支持强统计优越性结论。
- CodeT5-small 的模型容量有限，而且所有方法在超难查询上仍然很弱。
- 梯度近似只跟踪完整微调 CodeT5-small 的最后一个 decoder block，而原始实现使用的是 LoRA 最后一层的几何信息。
- 难度分组使用预训练损失分位数，而不是 LEAD 的 IFD 和语义 K-means 流程。
- EXP3 只接收 5 次决策反馈，这限制了策略学习，并使奖励容易受到训练轮次效应影响。
- 端到端时间仅在一套 Apple MPS 环境上测量，不能视为与硬件无关的吞吐量结论。
- Exact Match 十分严格，并不直接衡量执行等价性；辅助的规范化字符串诊断对格式更加敏感。

10. 结论

在固定 500 个样本的预算下，观测损失 IDU 在选数方法中取得最高平均成绩 17.08%；更贴近论文的训练期梯度改造得到 15.94%，接近随机方法的 15.64%。实验支持迭代式效用更新和累积回放是有用的设计元素，但没有证明当前梯度近似或 EXP3 分配能够带来稳定准确率增益。全量数据仍明显更强，达到 23.02%。

最可辩护的结论是一个同时包含正向和负向证据的受控发现：累积回放能够避免严重遗忘，动态选择会改变最终选中的数据；但当前 EXP3 奖励与粗粒度难度簇没有带来可靠的泛化增益。这直接说明了在小规模 Text-to-SQL 中，LEAD 改造在什么情况下有帮助，以及其假设在哪里变弱。

11. 有依据的下一步工作

1. 重新设计 EXP3 奖励，将难度臂本身的价值与后期训练轮次带来的一般性改善分离，再与同一个平衡对照进行测试。
2. 在不改变唯一数据总量和优化步数预算的前提下，提高分配频率或增加轮数，让 bandit 获得更多反馈决策。
3. 用基于数据库模式和 SQL 结构的 Text-to-SQL 感知分组替代损失分位数簇；只有在完成这项针对性设计测试后，再考虑增加随机种子或使用更大模型。

参考文献

- [1] T. Yu 等. Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task. EMNLP, 2018.
- [2] Y. Wang 等. CodeT5: Identifier-aware Unified Pre-trained Encoder-Decoder Models for Code Understanding and Generation. EMNLP, 2021.
- [3] X. Lin 等. LEAD: Iterative Data Selection for Efficient LLM Instruction Tuning. PVLDB 19(3):426-439, 2025. doi:10.14778/3778092.3778103.